


Графовые методы кластеризации.

Представим данные в виде графа.

$$G = (V, E)$$

vertices edges

1) Полный взвешенный граф.



1) Adjacency matrix V


2) Adjacency list X

$$V \rightarrow \begin{pmatrix} 0 & w_{12} & & \\ w_{21} & 0 & & \\ & & \ddots & \\ & & & 0 \end{pmatrix}$$

Симметрич.
Несмп. орг.
 $w_{ij} \geq 0$
 $w_{ij} = w_{ji}$

Spectral. . . .

2) Кластеризация через MST
Minimum Spanning Tree



1) Строим граф (полный)


2) Строим MST

3) Удаляем $k-1$ самых больших рёбер

3) ϵ -графы

Соединены в графе только те точки, которые лежат в ϵ -окрестности

Вершина x_i может быть связана только с x_j s.t. $\rho(x_i, x_j) < \epsilon$



4) Соединены точки x_i с $e \in p$ если
соседями p -NN графа

Методы ускорения

1) Считать по формулам (k-медиан)

Пересчитываем центроиды не по всем данным

2) Считать не по всей выборке ???

3) NSW ?

4) Повышать размерности

5) Делать модели поверх обученной метрики

Спектральная кластеризация

$G = (V, E)$ — неориентированный граф

$$W = (w_{ij})_{i,j=1,\dots,n}$$

Степени вершин v_i :

$$d_i = \sum_{j=1}^n w_{ij}$$

D — диагональная матрица $D_{ii} = d_i$

Лемма Гривера:

$$L = D - W$$

1) $f \in \mathbb{R}^n$:

$$\boxed{f^T L f} = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2$$

$$\begin{aligned} f^T L f &= f^T D f - f^T W f = \\ &= \sum_{i=1}^n d_i f_i^2 - \sum_{i,j} f_i f_j w_{ij} = \end{aligned}$$

$$= \frac{1}{2} \left(\sum_{i=1}^n d_i f_i^2 - 2 \sum_{i,j} f_i f_j w_{ij} + \sum_{j=1}^n d_j f_j^2 \right) =$$

$$= \frac{1}{2} \left(\sum_{i=1}^n \sum_{j=1}^n w_{ij} f_i - 2 \sum_{i,j} f_i f_j w_{ij} + \sum_{j=1}^n \sum_{i=1}^n w_{ij} f_j^2 \right) =$$

$$= \frac{1}{2} \sum_{i,j} w_{ij} \underbrace{(f_i - f_j)^2}_{\geq 0} \geq 0$$

2) L — симметричная, неотрицательно

полуопределённая матрица

- 3) Наибольшее собствен. значение = D
и соотв. вектору $\mathbf{1} = (1, \dots, 1)^T$

Алгоритм:

- 1) $L = D - W$
- 2) Найти С.В. u_1, \dots, u_n
- 3) Выбрав k собствен. векторов с наиб. собствен. значениями.
 $U = (u_1, \dots, u_k) \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$
- 4) Кластеризация выборки U с помощью k -means.

$k = 2$

Graph-cut

W - сходимость объектов в графе

$$W(A, B) = \sum_{i \in A} \sum_{j \in B} w_{ij}$$

$$A_k \subset V \quad A_i \cap A_j = \emptyset$$

$$\text{cut}(A_1, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k W(A_i, \bar{A}_i) \rightarrow \min$$

$$\text{Ratio Cut}(A_1, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, \bar{A}_i)}{|A_i|}$$

$$\min_{A \subset V} \text{RatioCut}(A, \bar{A})$$

$$f = (f_1, \dots, f_n)^T$$

$$f_i = \begin{cases} \sqrt{|\bar{A}|/|A|}, & v_i \in A \\ -\sqrt{|A|/|\bar{A}|}, & v_i \in \bar{A} \end{cases}$$

$$f^T L f \stackrel{\rightarrow}{=} n \text{RatioCut}(A, \bar{A})$$

$$f^T L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 =$$

$$= \frac{1}{2} \sum_{i \in A, j \in \bar{A}} w_{ij} \left(\sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2 +$$

$$\frac{1}{2} \sum_{i \in \bar{A}, j \in A} w_{ij} \left(-\sqrt{\frac{|A|}{|\bar{A}|}} - \sqrt{\frac{|\bar{A}|}{|A|}} \right)^2 =$$

$$= \frac{1}{2} \left(\sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2 (w(A, \bar{A}) + w(\bar{A}, A)) =$$

$$= \frac{1}{2} \left(\frac{|\bar{A}|}{|A|} + 2 + \frac{|A|}{|\bar{A}|} \right) (w(A, \bar{A}) + w(\bar{A}, A))$$

$$= \frac{1}{2} \left(\frac{|\bar{A}| + |A|}{|A|} + \frac{|A| + |\bar{A}|}{|\bar{A}|} \right) (w(A, \bar{A}) + w(\bar{A}, A))$$

$$u \quad \frac{1}{2} \left(\frac{1}{|A|} + \frac{1}{|\bar{A}|} \right) (w(A, \bar{A}) + w(\bar{A}, A))$$

$$\frac{w(A, \bar{A})}{|A|} + \frac{w(\bar{A}, A)}{|\bar{A}|} + \frac{w(A, \bar{A})}{|A|} + \frac{w(\bar{A}, A)}{|\bar{A}|}$$

$$= u \text{ RatioCut}(A, \bar{A}) \quad ??$$

$$\sum_{i=1}^n f_i = 0 \quad \sum_{i=1}^n f_i^2 = u$$

$$f^T L f \rightarrow \min_f$$

$$\langle f, \vec{1} \rangle = 0$$

$$\|f\| = \sqrt{n}$$

$$\mathcal{L} = f^T L f + \lambda_1 f^T \vec{1} + \lambda_2 (\|f\| - \sqrt{n})$$

$$\nabla_f \mathcal{L} = 2 L f + \lambda_1 \vec{1} + \lambda_2 \frac{1}{\|f\|} f = 0 \quad | \cdot \vec{1}^T$$

$$2 \vec{1}^T L f + \lambda_1 n = 0$$

$$\lambda_1 = - \frac{2 \vec{1}^T L f}{n}$$

$$\lambda_1^T = - \frac{2}{n} f^T \left(\vec{1} \right) = 0$$

$$2 L f + \lambda_2 \frac{f}{\|f\|} = 0$$

$$L f = \left(\frac{\lambda_2}{2\sqrt{n}} \right) f \quad \lambda_2$$

$$f^T L(f) = f^T \Delta f = \Delta \|f\|^2 = 2n \rightarrow \min$$

минимум достигается на 2-м
с.б. L и с.б. Δ

$$\begin{cases} v_i \in A, \text{ если } f_i \geq 0 \\ v_i \in \bar{A}, \text{ если } f_i < 0 \end{cases}$$

