

МО с учителем

$X = \{(x_i, y_i)\}_{i=1}^L$  - обучающая выборка

$$a(x_i) \approx y_i$$

$$Q(a, X) \rightarrow \min_{a \in A}$$

МО без учителя Unsupervised learning.

$$X = \{x_i\}_{i=1}^L$$

нужно этого решить с  $X$

Кластеризация

$$X = \{x_i\}_{i=1}^L$$

хотим  $a: X \rightarrow \{1, \dots, k\}$   
модель кластеризации

$$x_i \text{ и } x_j \text{ похожи} \Leftrightarrow a(x_i) = a(x_j)$$



# Зачем

## 1) Исследование рынка

- социологический опрос.
- телефонный оператор
- кластеризация телестов

## 2) Генерация новых признаков

- добавить категориальный признак
- добавить расстояния 1...K.  
до центров кластеров





## Метрики качества кластеризации

а) Посмотреть шумы

б) Внутрикластерное расстояние требует "компактность кластеров"

$$\sum_{k=1}^K \sum_{i=1}^L [a(x_i) = k] p(x_i, c_k) \Rightarrow \min$$

$c_k$  - центр  $k$ -го кластера




## 2) Межкластерное расстояние

Требуется чтобы кластеры были "различны"

$$\sum_{i \neq j} [a(x_i) \neq a(x_j)] p(x_i, x_j) \rightarrow \max$$

разн. от разн.



## 3) Комбинированное расстояние

Индекс Данна


$d(k, k')$  - расстояние между кластерами  $k$  и  $k'$

$d(k)$  - внутриматричное расстояние

$$\min_{1 \leq k \leq k' \leq K} d(k, k')$$

$$\max_{1 \leq k \leq K} d(k)$$

$\rightarrow \max$




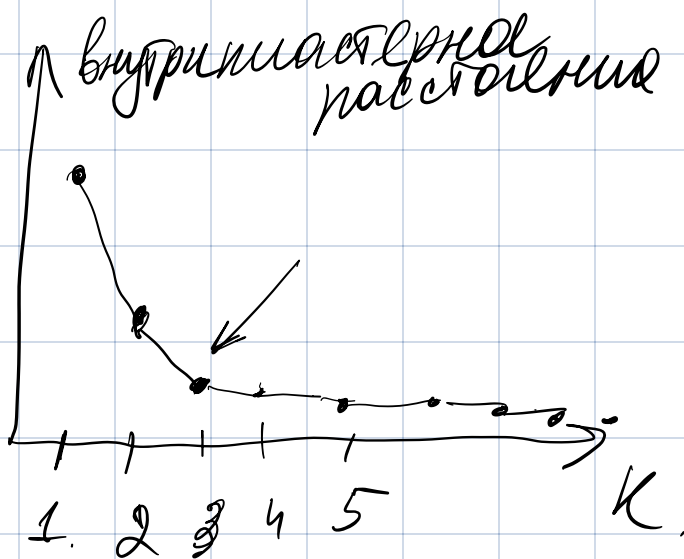
• метод выбора  $K$  - кол-во кластеров реализован внутри алгоритма кластеризации

•  $k$  - гиперпараметр.

Как подобрать  $k$ ?

1) Смотреть графики

2)  $el\&ol$  method



$k$ -means.

$\rho(x, z)$  - какое-то расстояние

$k$  - гиперпараметр, число кластеров

$$\sum_{k=1}^K \sum_{i=1}^n [\underline{a}(x_i) = k] f(x_i, \underline{c}_k) \Rightarrow \min_{a, c_k}.$$

$c_k$  - центр кластера  $k$ .

Шаг 0 Инициализируем центры  $c_k$

Шаг 1 Фиксируем  $c_k$ .

$$a(x_i) = \arg \min_{k=1, \dots, K} f(x_i, c_k)$$

Шаг 2 Фиксируем  $a(x_i)$

Ищем центр масс

$$c_k = \arg \min_c \sum_{a(x_i)=k} f(x_i, c)$$

$$\text{если } f_{(x, c)} = \|x - c\|^2$$

$$c_k = \frac{\sum_{i=1}^n [\underline{a}(x_i) = k] \cdot x_i}{\sum_{i=1}^n [\underline{a}(x_i) = k]}$$